

도메인 지식 정리 (발표 Q&A 대응용)

본 문서는 발표 도중·이후 받을 수 있는 질문에 즉답하기 위한 정리.

1. 채권 심화, 2) 거시경제·금리 용어, 3) 데이터 소스, 4) 분석 기법, 5) 모델·평가 용어, 6) 예상 Q&A.

1. 채권 심화 (Bond Deep Dive)

1.1 채권이란

****채권(Bond)****은 발행자(정부·기업)가 투자자에게 돈을 빌리고 만기에 원금을 갚되 정기적으로 이자를 지급하기로 약속한 증권. 정부가 발행하면 **국채(Treasury Bond)**, 기업이 발행하면 회사채.

핵심 3요소:

- **액면가(Face Value)**: 만기에 돌려받을 원금. 한국 국고채는 보통 1만원 단위.
- **표면금리(Coupon Rate)**: 발행 시 정해진 이자율. 액면가 × 표면금리 = 매년/반기 받는 이자.
- **만기(Maturity)**: 원금 상환 시점. 1·3·5·10·30년물 등.

1.2 YTM (Yield to Maturity, 만기수익률) — 우리 타겟

YTM은 "이 채권을 지금 가격에 사서 만기까지 보유했을 때의 연환산 총수익률". 시장에서 거래되는 가격이 변하면 YTM도 변한다. 우리가 예측하는 "금리"가 바로 YTM.

헷갈리기 쉬운 점: 표면금리는 발행 시 고정, YTM은 매일 변함. 뉴스에서 "국고채 10년 금리 3.45%"라고 할 때의 그 수치가 YTM.

1.3 가격-금리 역관계 (가장 중요한 채권 상식)

채권 가격 ↑ ⇔ 금리(YTM) ↓ (반비례). 이유:

- 액면가 1만원, 표면금리 3% 채권을 9,500원에 사면, 받는 이자는 같은 300원이지만 투자 원금이 적으니 수익률(YTM)이 높아짐.
- 반대로 9,500원이던 채권이 10,500원으로 오르면 같은 이자에 비싼 가격을 치른 셈이라 YTM은 낮아짐.

→ **금리가 오른다 = 채권 가격이 떨어진다 = 채권 보유자 손실**. 채권 트레이더가 금리 예측에 사활을 거는 이유.

1.4 듀레이션 (Duration) — 금리 민감도

듀레이션은 금리 1%p 변할 때 채권 가격이 몇 % 움직이는지 측정. 만기가 길수록 듀레이션이 큼.

- 10년물 듀레이션 ≈ 8~9년 수준 → 금리 1bp 오르면 가격 약 0.08~0.09% 하락.
- **장기물(10년·30년)이 금리 변동에 가장 민감**해서 트레이더가 신중. 이게 우리가 10년물을 타겟으로 잡은 이유 중 하나(시장 대표성 + 변동성 적정).

1.5 bp (basis point, 베이스 포인트)

1bp = 0.01%p. 채권 시장의 표준 단위.

- "금리가 5bp 올랐다" = 0.05%p 올랐다 = 3.40% → 3.45%.
- 일별 한국 국고채 10년물 변동성은 평상시 1~5bp, 위기 시 10~30bp.
- 우리 타겟 단위가 bp인 이유: 일일 변화량이 작아 %로 표현하면 0.0345 같은 작은 수가 나와 시각화·해석이 불편.

1.6 국고채 10년물을 선택한 이유

1. **시장 대표성**: 한국 채권시장의 벤치마크. 회사채·주택담보대출·정기예금 금리 등이 10년물에 연동.
2. **정보 풍부도**: 거래량 많음 → 가격 신호 깨끗함.
3. **데이터 안정성**: ECOS 1995년부터 일별 시계열 제공.
4. **적정 변동성**: 1년물(단기)은 정책금리에 거의 고정, 30년물(초장기)은 거래량 적어 노이즈. 10년이 균형.

1.7 만기 갱신 (Roll-over, 지표채권 교체)

한국 국고채 10년물은 **분기마다 새 발행 채권으로 지표(benchmark)가 교체**됨. 교체일 ±2일에는 옛 채권과 새 채권의 가격 차이로 0.5~5bp 인공적 점프가 생김.

- 이는 시장의 진짜 신호가 아니라 발행 일정에 의한 기술적 점프.
- SHAP 분석에서 이를 학습하면 거시 변수 해석이 오염됨.
- 따라서 우리는 갱신일 ±2일을 **제외 옵션**으로 운영 (계획서 §2.3).

1.8 한국 채권시장 구조 (외국인·기관)

- 외국인 보유 비중: 전체 채권시장의 약 8~10% (2025년 기준), 그러나 단기 변동성의 60% 이상 설명.
- 주요 매수자: 국민연금, 보험사, 은행, 한국은행 (양적완화 시).
- → 외국인 자금 유출 시 금리 급등 (2022년 미국 금리 인상기 사례).
- 향후 확장 시 "외국인 채권 보유잔고" 변수 추가 검토 (계획서 §11 선택 확장).

1.9 국고채 vs 회사채 vs 통안채

종류	발행자	신용	우리 모델 사용
국고채 (KTB)	정부 (기획재정부)	무위험	타겟 + 1·3·5년물 입력
통안채 (MSB)	한국은행	무위험	(미사용)
회사채 (Corp)	기업	신용 위험	AA-3년 입력 (신용 스프레드 신호)

신용 스프레드 = 회사채 금리 - 국고채 금리. 경기 위험 신호로 활용.

1.10 채권 → 가계 부담의 인과 사슬 (선정 이유 핵심)

채권 자체가 가계 부담의 원인이 아니다. 채권 시장은 **거시 환경의 측정기 + 가격 전달 매개체**이며, 한국 현실에서는 가계 대출 금리의 결정 메커니즘 한가운데에 있다.

[진짜 원인]

- ① 한국은행 기준금리 결정 (정책)
- ② 글로벌 자금 흐름 (외국인 매수/매도)
- ③ 인플레이션 기대

↓

[측정 + 가격 발견]

국고채 10년물 YTM 변동 ← 가장 빨리·정확히 ①②③ 반영

↓

[은행 자금조달 비용]

코픽스(COPIX) = 예금금리 + 은행채 금리 가중평균

↑ 은행채는 국고채 + 신용 스프레드만큼 차이

↓

[가계 부담]

주담대·전세대·신용대 변동금리 = 코픽스 + 가산금리

매월 이자 ↑

오해 정정 — "은행이 채권 평가 손실을 메꾸려 대출 금리를 올린다"는 X. 진짜 메커니즘은 신규 자금조달 비용 상승의 전가:

- 시장금리 ↑ → 은행이 새로 발행할 은행채의 표면금리도 올려야 시장에서 팔림 → **자금조달 비용** ↑ → 그 비용을 대출 금리에 전가.
- 이미 보유한 채권의 평가손실은 회계상 별도 이슈일 뿐, 대출 금리에 직접 반영되지 않음.

비유: 채권 시장 YTM = 온도계 눈금, 거시 환경 = 진짜 더위, 가계 대출 금리 = 에어컨 사용료. 사용료는 "온도계가 가리키는 온도"를 보고 결정됨.

선정 이유 4문장:

1. 국고채 10년물 = 한국 모든 장기 금융상품의 벤치마크 (직접 영향력).
2. 청년·서민이 영끌·전세·학자금으로 이 금리에 가장 노출 (사회적 의의).
3. ECOS-FRED 무료 공공 데이터로 16년 일별 시계열 확보 가능 (실현 가능성).
4. 학부 ML 프로젝트에서 채권 도메인 드물어 차별화 (포트폴리오 가치).

1.11 한은 발표 효과의 시간 분포 (3단계)

발표날에 채권 가격 낙폭이 한 번에 정해지지 않음. 3단계로 분산:

[1단계] 선반영 (발표 전 1~2주)

시장이 "다음 인상 확률"을 미리 가격에 녹임

예: "25bp 인상 확률 80%" → 발표 전 약 20bp(25×0.8) 미리 오름

[2단계] 발표 당일 (Surprise effect)

컨센서스 vs 실제의 차이만 반영

└ 예상대로 25bp → 거의 안 움직임 (이미 다 반영)

└ 매파 서프라이즈 (50bp) → 추가 급락 (가격↓ / YTM↑)

└ 비둘기 서프라이즈 (동결) → 반등

[3단계] 중기 가이드언스 (1주~1개월)

총재 회견·의사록·인플레 전망에 따라 추가 조정

한은 표준 인상폭: 25bp(베이비스텝) / 50bp(빅스텝) / 75bp(자이언트스텝). 1bp 단위로 안 움직임.

모델 합의: 이벤트 더미 ±1일은 1단계 후반 + 2단계 + 3단계 초반을 잡음. 3단계 가이드언스 효과는 미국 BEI·한미 스프레드 변화 같은 다른 변수가 잡아주길 기대.

1.12 레벨 vs 변화량의 상관 갭 (왜 변화량을 타겟으로 잡았나)

보는 방식	한은 기준금리 vs 국고채 10년 상관	이유
레벨 (y_t)	매우 높음 (0.85~0.95)	둘 다 우상향/우하향 추세 공유
변화량 (Δy_t)	매우 낮음 (0.05~0.15)	빈도 차이 + 장기금리는 다른 동인 우세

왜 레벨 상관만 높은데도 예측이 어려운가:

1. **가짜 상관 (spurious)**: 비정상 시계열 둘이 같은 추세 공유 $\rightarrow R^2$ 0.9+ 자동. 통계적 의미 없음.
2. **빈도 차이**: 기준금리는 한 달 0~1번 점프, 국고채는 매일 변동.
3. **장기금리는 다른 동인 우세**: 10년물 = 한은 기준금리 + 미국 10년물 + 인플레이 기대 + 글로벌 자본 흐름 + 재정. 실증적으로 한국 10년물 일별 변화량을 가장 잘 설명하는 변수는 **미국 10년물(us10y)** — 한은 기준금리보다 영향력이 큼.

프로젝트 의미: "기준금리 따라가면 되는 거 아냐?"는 단기금리에서나 통함. 10년물은 22~27개 거시 변수 종합 모델이 필요. EDA(VIF-Granger)에서 어떤 변수가 진짜 일별 변화량을 설명하는지 정량 검증.

2. 거시경제·금리 핵심 용어

2.1 기준금리 vs 시장금리

- **기준금리(Base Rate, Policy Rate)**: 한국은행이 결정. 매월 금통위에서 발표. 7일물 RP 거래 금리.
- **시장금리(Market Rate)**: 시장에서 결정. 국고채 YTM이 대표.
- 일반적으로 기준금리 변경 $\rightarrow$ 단기 시장금리 즉시 반영, 장기금리는 시차·기대 반영해 천천히.

2.2 인플레이션 지표

- **CPI (Consumer Price Index, 소비자물가지수)**: 소비자가 사는 상품·서비스 가격. 매월 발표.
- **근원 CPI (Core CPI)**: CPI에서 변동성 큰 식품·에너지 제외. 추세적 인플레이션 신호.
- **PPI (Producer Price Index, 생산자물가지수)**: 기업이 받는 출하 가격. CPI의 선행지표 역할.
- **BEI (Breakeven Inflation, 기대 인플레이션)**: 명목금리 - 실질금리 = 시장이 기대하는 미래 인플레이션. 미국은 10년물 BEI가 표준 지표.

2.3 글로벌 위험·자산 시장

- **VIX (Volatility Index, 변동성 지수)**: S&P500 옵션 내재 변동성. **공포 지수**라고도 부름. 평상시 12~18, 위기 시 30+.
- **HY OAS (High Yield Option-Adjusted Spread)**: 미국 하이일드 회사채 신용 스프레드. 신용 위험 지표.
- **DXY (US Dollar Index, 달러 인덱스)**: 달러 vs 6개 주요 통화 가치. 신흥국 자본 흐름 지표.
- **WTI (West Texas Intermediate)**: 미국 서부 텍사스 원유 가격. 글로벌 인플레이션 채널.
- **KOSPI / S&P500**: 한·미 주가지수. 위험 자산 선호 신호.

2.4 정책 이벤트 더미 (4개)

- **FOMC (Federal Open Market Committee)**: 미국 연방공개시장위원회. 연 8회, 미국 기준금리 결정. 발표일 전후 글로벌 금리 변동성 폭증.
- **BOK 금통위 (한국은행 금융통화위원회)**: 한국 기준금리 결정. 연 8회.
- **美 NFP (Non-Farm Payrolls, 비농업 고용)**: 매월 첫째 금요일. 미국 고용 시장 대표 지표.
- **美 CPI 발표**: 매월 10~15일. 인플레이션 신호.

→ 이 4개 이벤트 ± 1 일은 일별 채권 변동성의 가장 큰 외생 충격. 이벤트 더미로 명시 모델링하지 않으면 "큰 변동 미세측" 오류 다수 발생.

3. 데이터 소스 (어디서 무엇을)

3.1 ECOS (한국은행 경제통계시스템)

- URL: <https://ecos.bok.or.kr/>
- 무료 공공 API (인증키 발급).
- 우리가 가져오는 것: **국고채 1·3·5·10년 금리(YTM 지표금리)**, 회사채 AA-3년, CD 91일, 기준금리, CPI/근원 CPI/PPI, 산업생산, 제조업 BSI, 원/달러 환율(검증용).
- 빈도: 일별(D) 또는 월별(M).
- 기간: 1990년대~ (10년물은 2000년부터 안정).

3.2 FRED (Federal Reserve Economic Data, 세인트루이스 연준)

- URL: <https://fred.stlouisfed.org/>
- 무료 공공 API (인증키 발급).
- 우리가 가져오는 것: **DGS10**(미국 10년 국채), **DGS2**(미국 2년 국채), **DFF**(연방기금 실효금리), **T10YIE**(10년 BEI), **CPIAUCSL**(미국 CPI), **VIXCLS**(VIX), **BAMLH0A0HYM2**(HY OAS), **DCOILWTICO**(WTI), **DTWEXBGS**(달러 인덱스 광역).

3.3 yfinance (Yahoo Finance API)

- 파이썬 라이브러리 **yfinance** (비공식이지만 안정적).
- 우리가 가져오는 것: **^KS11**(KOSPI), **^GSPC**(S&P500).
- ECOS·FRED에 주가지수가 없어서 보조 사용.

3.4 이벤트 캘린더

- FOMC 일정: 연준 공식 사이트 발표 일정 캘린더.
- 한은 금통위: 한국은행 보도자료 일정.
- 美 NFP: BLS (Bureau of Labor Statistics) 매월 첫째 금요일.
- 美 CPI: BLS 매월 10~15일.
- → 코드에서 날짜 리스트로 하드코딩 + 발표일 ± 1 일 더미 자동 생성.

4. 기초 분석 기법 (EDA & Stats)

4.1 정상성 (Stationarity)

시계열의 평균·분산이 시간에 따라 일정한지. **금리 레벨은 비정상**(추세 있음), **금리 변화량(Δy)은 보통 정상**. 이게 우리가 변화량을 타겟으로 잡은 통계적 이유.

- **ADF test (Augmented Dickey-Fuller)**: 단위근(non-stationarity) 검정. p-value < 0.05면 정상.
- **차분(differencing)**: 비정상 시계열을 정상으로 만드는 가장 흔한 방법. $\Delta y_t = y_t - y_{t-1}$.

4.2 자기상관 (Autocorrelation)

시계열 자신과의 시차별 상관.

- **ACF (Autocorrelation Function)**: 시차 k 자기상관.
- **PACF (Partial ACF)**: 중간 시차 영향 제거한 순수 시차 k 효과. ARIMA 차수 결정에 사용.

4.3 상관관계 매트릭스 (Correlation Matrix)

변수 쌍별 Pearson 상관계수. **0.8 이상은 다중공선성 의심**.

- 우리 프로젝트에서 1차 변수 압축 도구.

4.4 VIF (Variance Inflation Factor, 분산 팽창 계수)

다변량 회귀에서 변수 i 의 다중공선성 진단. **VIF > 10이면 심각, > 5면 주의**.

- 계산: $VIF_i = 1 / (1 - R^2_i)$ (R^2 는 변수 i 를 다른 변수들로 회귀한 결과).
- 채권 모델에서 흔한 함정: us10y와 us2y는 상관 0.95+ → VIF 폭발. 둘 중 하나만 쓰거나 한미 스프레드 같은 합성 변수 사용.

4.5 Granger 인과성 (Granger Causality)

"변수 X 의 과거 값이 변수 Y 의 미래 예측에 도움이 되는가?"를 통계적으로 검정. **진정한 인과는 아님** (이름이 잘못 붙음). 시차 효과 검증 도구.

- F-test 기반.
- 예: "미국 10년물 → 한국 10년물 Granger 인과성"이 시차 1~3일에서 유의하면 입력 변수로 정당화.

4.6 데이터 누수 (Data Leakage) — 시계열 특화

미래 정보가 학습에 새는 현상. 시계열 ML에서 가장 흔한 결과 무효화 원인.

- **K-fold 셔플 금지**: sklearn 기본 K-fold는 데이터를 섞음 → 미래로 과거 예측 발생. **TimeSeriesSplit** 또는 walk-forward 사용.
- **양방향 보간 금지**: `interpolate(method='linear')`는 결측을 좌우 값으로 보완 → 미래 값이 과거에 들어감.
- **정책 변수 $t-1$** : 기준금리는 발표 당일 종가에 반영되므로 학습 시 $t-1$ 시점 값 사용.
- **월별 변수 발표일 시프트**: CPI는 익월 초 발표 → 발표일 이후에만 사용 가능 (release-date join).

4.7 변화량 vs 레벨 (Δy vs y)

타겟	장점	단점
레벨 (y)	직관적	Naive(어제 = 오늘)가 너무 강해 모델 우위 입증 어려움. 비정상성.
변화량 (Δy)	정상성 확보, VaR 정합	Naive(=0) 예측의 RMSE도 매우 작아 RMSE 개선이 어려움 → 방향성·DM test로 차별화

우리는 변화량 + 분위수 회귀 = 채권 실무 적합 + 학술적 정상성 모두 만족.

5. 모델·평가 핵심 용어

5.1 베이스라인 모델

- **Naive (변화량 모델):** $\Delta \hat{y}_{\{t+1\}} = 0$ (내일 변화 없음). 일별 채권에서 의외로 강력.
- **ARIMA (AutoRegressive Integrated Moving Average):** AR(자기회귀) + I(차분) + MA(이동평균). 단변량 시계열 표준.
- **XGBoost (Extreme Gradient Boosting):** 트리 기반 부스팅. 표 데이터 ML 표준.
`objective="reg:quantileerror"`로 분위수 회귀 가능.

5.2 LSTM (Long Short-Term Memory)

순환 신경망(RNN)의 한 종류. 게이트 구조로 장기 의존성 학습.

- **Forget Gate:** 과거 정보 중 무엇을 잊을지.
- **Input Gate:** 새 정보 중 무엇을 저장할지.
- **Output Gate:** 다음 시점에 무엇을 출력할지.
- 시계열·자연어에서 표준이었으나 최근에는 Transformer가 더 우세. 그러나 **소량 데이터(우리는 16년치 ≈ 4,000일)**에서는 **LSTM이 안정적**.

5.3 분위수 회귀 (Quantile Regression)

점추정(평균) 대신 **분위수**(예: 5%-50%-95%)를 직접 예측.

- 손실 함수: **Pinball Loss (Quantile Loss)**.

$$L_q(y, \hat{y}) = \max(q \cdot (y - \hat{y}), (q - 1) \cdot (y - \hat{y}))$$

- $q = 0.5$ 면 MAE의 반과 동일 (중앙값 회귀).
- $q = 0.95$ 면 위쪽 5% 꼬리 예측에 큰 페널티.
- 출력 $[q0.05, q0.5, q0.95] \rightarrow$ **90% 예측 구간** = $(q0.05, q0.95)$.

5.4 SHAP (SHapley Additive exPlanations)

게임이론의 Shapley value를 ML 변수 기여도에 적용. **각 변수가 예측에 얼마나 기여했는지 정량화**. XAI(설명 가능 AI)의 표준.

- **TreeExplainer:** 트리 모델용 (XGBoost). 빠르고 정확.
- **DeepExplainer:** 딥러닝용 (LSTM). 근사.
- 우리는 분위수별로 따로 SHAP 적용 ($q0.05 \cdot q0.5 \cdot q0.95$ 각각) 후 차분 시각화로 "어떤 변수가 예측 구간을 넓히는가" 분석.

5.5 평가 지표

- **RMSE (Root Mean Squared Error):** $\sqrt{\text{평균}((y - \hat{y})^2)}$. 큰 오차에 민감.
- **MAE (Mean Absolute Error):** $\text{평균}(|y - \hat{y}|)$. 이상치에 강건.
- **방향성 정확도 (Directional Accuracy):** $\text{sign}(\hat{y}) == \text{sign}(y)$ 의 비율. 금융 실무 핵심.
- **Coverage Rate:** 90% 예측 구간 안에 실제값이 들어온 비율. 목표 $90\% \pm 3\%p$.
- **Sharpness:** 예측 구간 평균 폭 $\text{mean}(q0.95 - q0.05)$. **좁을수록 좋음** (단, Coverage 충족 전제).

5.6 모델 비교 통계 검정

- **DM test (Diebold-Mariano)**: 두 예측 모델의 정확도 차이가 통계적으로 유의한지 검정.
- **HLN 보정 (Harvey-Leybourne-Newbold)**: 소표본에서 DM 통계량 보정. $n < 200$ 권장.
- **HAC 표준오차 (Heteroskedasticity and Autocorrelation Consistent, Newey-West)**: 자기상관·이분산성 보정.
- **Bonferroni 다중비교 보정**: 여러 모델을 동시 비교할 때 false positive 통제.

5.7 보정 (Calibration)

- **Conformal Prediction (CP)**: 분포 가정 없이 marginal coverage 보장하는 후처리. 시계열에서는 점근적·근사.
- **CQR (Conformalized Quantile Regression)**: 분위수 회귀 + CP. 라이브러리 [mapie](#).
- 우리는 raw 분위수가 $90\% \pm 3\%p$ 미달 시에만 선택 적용.

6. 예상 Q&A 대응

Q1. 왜 환율을 입력에서 뺐나? 거시 시계열에 환율은 핵심 아닌가?

A. 정성·정량 두 근거:

1. **정성**: 한국은행-국민연금 외환스왑 650억 달러 한도 운영, 1,500원 방어선 시 외환당국 직접 흡수, 연말 증가 관리 등 **정부 개입이 환율을 시장 신호가 아닌 정책 신호로 만들**. 학습되면 거시 인사이트가 오염.
 2. **정량**: 5주차에 환율 포함/제외 ablation 실시. Pinball-Coverage-Sharpness-RMSE 비교 후 결과 공개.
- 환율의 정보 손실은 DXY(달러 인덱스 광역)로 일부 보완.

Q2. 왜 분위수 회귀인가? 점추정으로도 되지 않나?

A. 채권 실무에서는 **VaR·리스크 한도 산정**이 평균이 아닌 꼬리(tail)에 의존. 트레이더가 헷지 비용을 결정할 때 "평균 5bp 오를 것"보다 "95% 확률로 +20bp 이내"가 훨씬 유용. 분위수 회귀는 이 정보를 직접 출력.

Q3. 왜 LSTM인가? Transformer가 더 좋지 않나?

A. **데이터 규모**가 결정 요인. 우리 데이터는 16년 × 영업일 $\approx 4,000$ 일. Transformer는 이보다 10배 이상 데이터가 있어야 LSTM을 앞지름. 소량 시계열에서는 LSTM이 학습 안정성·과적합 방어 모두 우세. 시간 여유 시 Temporal Fusion Transformer 비교를 §11(선택 확장)에 둬.

Q4. 방향성 55%가 진짜 의미 있나? 동전 던지기 50% 대비 5%p 차이 아닌가?

A. **효율적 시장 가설**상 50%를 의미 있게 이기는 것 자체가 어려움. 학술 합격선은 52~53% (DM test 유의). 헤지 펀드가 ML에 거액을 투자하는 이유가 바로 이 2~3% 알파. 우리는 단순 "55% 맞혔다"가 아니라 **DM test + HLN 소표본 보정 + Bonferroni**로 우연이 아님을 통계적으로 입증.

Q5. Coverage 90%가 안 나오면?

A. 두 단계 대응:

1. **§6.4(c) Coverage Miss 분석** — 위기 구간에 몰려 있는지, covariate shift 진단.
2. **CQR (Conformal) 후처리** — [mapie](#) 라이브러리로 적용. 단, marginal coverage 보장은 점근적이라 distribution shift에서 깨질 수 있음을 명시.

Q6. 왜 10년물인가? 다른 만기는?

A. 시장 대표성·정보 풍부도·데이터 안정성·적정 변동성의 균형. 1년물은 정책금리에 거의 고정되어 변동성이 낮고, 30년물은 거래량이 적어 노이즈가 큼. 회사채·주택담보대출·정기예금 금리가 모두 10년물에 연동되어 실무 영향력이 가장 큼.

Q7. 왜 레벨이 아니라 변화량(Δy)인가?

A. 두 이유:

1. **통계**: 금리 레벨은 비정상(non-stationary), 변화량은 정상(stationary) → 모델 학습 안정.
2. **모델 우위 입증**: 레벨 예측에서는 Naive(어제 = 오늘)가 너무 강해 LSTM 우위를 보이기 어려움. 변화량 + 분위수 회귀 구조에서 차별화 가능.

Q8. 이벤트 더미는 어떻게 처리하나?

A. FOMC·금통위·美 NFP·美 CPI 발표일 ± 1 일을 1, 그 외 0인 binary 변수. **± 1 일** 폭은 사전·당일·익일 모두 변동성이 큼을 반영. 5주차 ablation에서 $\pm 0/\pm 1/\pm 2$ 비교 검토.

Q9. 외국인 채권 보유잔고는 왜 안 쓰나?

A. 데이터 수집 부담(주별 지연 발표 + 일별 환산 필요)으로 v5 본문에서 보류. 1주차 EDA 결과 핵심 결손이 보이거나 시간 여유가 생기면 §11(선택 확장)에서 추가. 한미 스프레드(**kr10y** - **us10y**)도 동일.

Q10. AI 도구를 얼마나 썼고 어떻게 검증했나?

A. Claude Code + 3개 subagent로 데이터 파이프라인·모델 코드 작성. 검증은 **매주 2건 이상 수동 검증 → 7주간 14건 이상**을 **VALIDATION_LOG.md**에 누적. 안내문 권장 최소 3건의 4.5배. 데이터 누수 7개 체크리스트(**data_leakage_checklist.md**)는 매 PR마다 점검.

Q11. 왜 22개 변수인가? 더 많이/적게가 좋지 않나?

A. **Box & Jenkins Parsimonious Model** 원칙: 광역 22개 수집 → EDA(상관·VIF·Granger)로 8개 압축. 변수 선정 근거를 사전 이론이 아닌 **데이터로 정당화**. ablation 결과에 따라 ± 2 개 유연 조정.

Q12. 변수 freeze는 언제·어떻게 하나?

A. **3주차 금요일 잠정 freeze** (8개 + 사유 문서화) + **5주차 ablation 대상 사전 명시**. "잠정 freeze가 결과적 freeze로 굳어지는" 함정을 막기 위해 안전장치 3개:

1. 3주차 산출물 4건 강제 (상관·VIF·Granger·문서).
2. ablation 대상 3주차에 결정 (5주차에 미루기 금지).
3. 음수 채택 원칙 (결과 부정적이어도 그 자체를 보고).

Q13. 위기구간은 어떻게 정의하나?

A. **정량 정의**:

위기일 = (kr_treasury_10y의 20일 rolling vol 상위 20%) $\cup$ (이벤트 더미 활성화일 ± 1 일)

서사가 아닌 코드 라벨링 → 평가 신뢰도 확보.

Q14. 데이터 분할은?

구간	기간	길이
Train	2010-01 ~ 2020-12	11년
Calibration	2021	1년
Validation	2022	1년
Test	2023-01 ~ 2025-12	3년

Test에 미국 금리 인상기·2024 계엄·2025 고환율 등 극단 이벤트 포함 → 강건성 검증.

Q15. 7주 만에 다 가능한가?

A. v5는 **선택 사항을 명확히 분리**해 위험 최소화:

- 필수: Naive-ARIMA-XGBoost-LSTM 분위수 + 환율 ablation 1회 + 4축 오류 분석 + Streamlit 1페이지.
- 선택: CQR-Optuna-t+5 확장·추가 ablation-Adaptive CP 등 모두 시간 여유 시.
- 일정 지연 시 우선순위: 메인 모델 ≫ 차별화 ≫ 학술 강화.

Q16. 채권이 가계 부담의 직접 원인인가? 채권 없어도 금리 상승은 가계 부담 아닌가?

A. **채권은 원인이 아니라 측정기 + 가격 전달 매개체**입니다 (§1.10 참조). 진짜 원인은 한은 정책·글로벌 자금 흐름·인플레이 기대이고, 채권 YTM이 이를 가장 빠르게 가격에 반영. 한국 현실에서는 코픽스(은행채 + 예금금리 가중)를 통해 변동금리 대출이 자동 연동되므로 **국고채 금리 = 가계 대출 금리의 1차 결정 변수**. 채권 시장이 없는 가상 세계라면 한은 정책금리만으로도 일부 전파되지만, 한국에서는 채권이 한가운데에 끼어 있는 **준직접적 영향**.

Q17. 한은이 인상하면 은행이 손실 메꾸려고 대출 금리를 올리는 건가?

A. **아닙니다. 메커니즘이 다릅니다.** 은행이 대출 금리를 정하는 공식:

$$\text{대출 금리} = \text{코픽스(자금조달 비용)} + \text{가산금리}$$

한은 인상 → 시장금리 ↑ → 은행이 새로 발행하는 은행채 표면금리도 올려야 시장에서 팔림 → **은행 신규 자금 조달 비용 ↑** → 그 비용을 대출에 전가. 이미 보유한 채권의 평가손실을 메꾸는 게 아니라 앞으로 빌릴 돈이 비싸졌으니 빌려주는 가격도 올리는 **도매-소매 가격 전가** 구조.

Q18. 한은 발표날에 채권 가격 낙폭이 한 번에 정해지나?

A. **아닙니다. 3단계로 분산** (§1.11 참조):

- 선반영**(발표 전 1~2주): 시장이 인상 확률을 미리 가격에 녹임 (예: 80% 확률 × 25bp = 20bp 미리 반영).
- 발표 당일**: 컨센서스 vs 실제의 차이(서프라이즈)만 반영. 예상대로면 거의 안 움직임.
- 중기 가이드**(1주~1개월): 총재 회견·의사록·인플레이 전망에 따라 추가 조정.

이게 우리가 이벤트 더미를 ± 1 일로 잡은 이유. 컨센서스 데이터(블룸버그 서베이)가 있으면 "서프라이즈 자체"를 변수화할 수 있지만 무료 데이터 한계로 더미로 대체.

Q19. 한은 기준금리와 국고채 금리는 상관 너무 높지 않나? 변수 추가의 의미가 있나?

A. 레벨로는 **0.85~0.95로 매우 높지만, 일별 변화량으로는 0.05~0.15에 불과** (§1.12). 이유:

1. 레벨 상관은 **가짜 상관(spurious)** — 둘 다 비정상 시계열이라 추세 공유로 R^2 자동.
2. **빈도 차이** — 기준금리는 한 달 0~1번 점프, 국고채는 매일 변동.
3. **장기금리는 다른 동인 우세** — 10년물 일별 변화량을 가장 잘 설명하는 변수는 한은 기준금리가 아니라 **미국 10년물·VIX·BEI·DXY**.

→ 단순 추종이 안 통하므로 22~27개 거시 변수 종합 모델이 필요. EDA에서 어떤 변수가 진짜 신호인지 정량 검증한 결과 자체가 발표 인사이드가 됨.

Q20. 일별 변화량 예측이 실무에 어떻게 쓰이나? (변화량은 쓸모없지 않나?)

A. **변화량 $\equiv$ 레벨** — 어제 레벨 + 예측 변화량 = 내일 레벨 예측. 1-step 예측에서는 동일한 정보의 다른 표현. 다만 변화량 + 분위수 회귀의 **진짜 부가가치는 90% 예측 구간**:

활용	구체 사례
VaR / 리스크 관리	100억 보유, 듀레이션 8년 → 예측 구간 [-3, +12bp] → 최악 19억 평가손 → 자기자본 한도 점검
트레이딩·듀레이션 조정	방향성 55% × 매일 의사결정 누적 = 연 환산 알파 수%. 헤지펀드 ML 투자의 본질
헷지 비용·옵션 가격	Sharpness(구간 폭) $\uparrow$ = 변동성 신호 → 헷지 미리 걸어두기
거시 인사이드 (SHAP)	"이번 주 변동 폭 60%는 미국 BEI 급등 기여" → 한은 보고용 자료

활용 주체:

- 자산운용사 채권 펀드 매니저 — 일일 듀레이션·포지션 조정.
- 보험사 ALM — 장기 부채와 자산 듀레이션 매칭.
- 은행 트레저리 — 채권 포트폴리오 VaR 일일 산출.
- 한국은행 리서치 — 정책 인상 시 시장 반응 시뮬레이션.
- 개인 투자자(간접) — 채권 ETF 진입·예적금 만기 결정.

핵심: 단순 "내일 5bp 오른다"가 아니라 "90% 확률로 -3~+12bp"라는 정보가 실무 의사결정의 핵심.

7. 한 줄 요약 (발표 직전 컨닝페이퍼)

- **타겟:** 한국 국고채 10년물 일별 변화량 Δy (단위: bp), 분위수 [0.05, 0.5, 0.95].
- **데이터:** ECOS + FRED + yfinance, 2010~2025, 광역 27개(거시 22 + DXY + 이벤트 더미 4) + 검증용 환율 1 → 8개 압축.
- **모델:** Naive → ARIMA → XGBoost → LSTM 분위수 회귀.
- **평가:** 방향성 $\geq 55\%$ + DM test + Coverage 90% $\pm$ 3%p + Sharpness.

- **차별화:** 거시 도메인 + EDA 정량 변수 선정 + 환율 의도적 제외 + 위기구간 정량 정의 + 누수 7개 체크 + AI 검증 14건+.
- **인용:** Box & Jenkins(parsimony), Diebold-Mariano(1995), HLN(1997), Conformal Prediction(Vovk et al.).

8. 실무 활용 시나리오 + 학부 프로젝트 한계 (정직한 포지셔닝)

8.1 실무 활용 시나리오 5종 (Q&A 직접 인용 가능)

사용자	활용 방식	우리 모델 출력 중 핵심
자산운용사 채권 펀드 매니저	일일 듀레이션·포지션 조정	방향성(q0.5 부호) + 90% 구간 폭
보험사 ALM 부서	장기 부채와 자산 듀레이션 매칭, 변동 시 즉각 대응	q0.95(꼬리) + Sharpness
은행 트레저리	채권 포트폴리오 VaR 일일 산출, 자본 배분	90% 구간 + 위기구간 RMSE
한국은행 리서치	정책 인상 시 시장 반응 시뮬레이션, 의사록 작성 참고	SHAP 분위수별 + 위기 vs 정상 변수 차이
개인 투자자 (간접)	채권 ETF 진입·예적금 고정·변동 선택	방향성 + 중기 가이던스 변수

8.2 학부 7주 프로젝트의 정직한 한계

채점관 신뢰도 확보를 위해 한계를 명시:

- **실거래 시스템 X:** latency-robustness가 실시간 트레이딩 수준이 아님. 백테스트 수익률 산출 안 함.
- **거래 비용·세금·유동성 미반영:** 매매 호가 스프레드, 채권 결제 T+1, 대량 거래 시장 충격 등 미고려.
- **시장 미시구조 미반영:** 호가 잔량, 외국인·기관 매매 동향 등 일중 데이터 없음.
- **데이터 지연 가공:** 외국인 보유잔고·통화량 같은 주간/월간 지연 발표 데이터는 미수집.
- **모델 단일성:** 단일 LSTM 분위수 회귀. 앙상블·다단 예측·강화학습 미적용.

→ **포지셔닝:** "실무 컨셉 검증(proof of concept) 수준의 모델". 학술적 엄격성과 실무 정합성을 균형 있게 추구 하되, 실거래 배포는 별도 엔지니어링 과제로 남김.

8.3 7주 후 확장 가능 항목 (포트폴리오·후속 연구)

- **외국인 채권 보유잔고 + 한미 스프레드** 추가 (계획서 §11).
- **t+5 확장:** 5영업일 ahead 분위수 회귀 (멀티 호라이즌).
- **Adaptive Conformal Inference:** distribution shift 적응 보정.
- **Walk-forward 3 fold + LSTM 재학습:** 과적합 방지.
- **CRPS 평가 지표 추가:** 분위수 회귀 표준.
- **실시간 대시보드:** Streamlit 1페이지 → FastAPI + 일일 자동 업데이트.
- **백테스트 모듈:** 거래 비용 모델 + 시뮬레이션 손익 곡선.

이 확장 목록 자체가 ***7주 모델은 끝이 아니라 출발점***이라는 메시지를 채점관에게 전달.

9. 모델별 작동 원리·강약점 (교수님 Q&A 대응 심화)

각 모델이 왜 그렇게 작동하는지 → 어떤 강점·단점이 생기는지 → 우리 프로젝트에서의 역할을 한 묶음으로 정리. 발표·구술시험에서 "이 모델은 어떻게 동작하나요?" 류 질문 대응용.

9.1 Naive (변화량 모델)

정의

$$\Delta \hat{y}_{\{t+1\}} = 0 \quad (\text{내일 변화 없음} = \text{오늘 레벨 유지})$$

왜 이렇게 작동하는가

- 일별 채권 변화량의 **평균이 0에 매우 가까움** (장기 평균 ≈ 0). 단기에서는 random walk(무작위 보행)에 가까운 성질.
- 평균이 0이라면 점추정으로 0을 찍는 게 RMSE 측면에서 통계적으로 가장 안전한 선택.

강점

- 계산 비용 0, 학습 0. 즉시 배포.
- **금리 시장의 random walk 가설(efficient market)에 부합** — 시장이 효율적이라면 미래 변화는 예측 불가, 0이 최적.
- 어떤 모델이든 이걸 못 이기면 "ML 적용 의미 없음"이라는 강력한 기준선 제공.

단점

- 정보 활용 0%. 거시 변수·이벤트 무시.
- 분위수 정보 없음 → 90% 구간·VaR 산출 불가.
- 위기 구간에서 큰 변동을 절대 못 잡음.

우리 프로젝트에서의 역할

- **모든 모델이 반드시 이겨야 할 최소 기준선**. ARIMA·XGBoost·LSTM 모두 Naive 대비 DM test 통계 유의성을 보여야 함.
- 이게 의외로 강해서, 일별 채권 RMSE에서 LSTM이 Naive를 크게 못 이기는 게 문헌의 일반적 결과 → 우리가 차별화 지표를 방향성·DM·Coverage·Sharpness로 옮긴 핵심 이유.

9.2 ARIMA (AutoRegressive Integrated Moving Average)

정의 — 3개 부품 합성

$$\text{ARIMA}(p, d, q) = \text{AR}(p) + \text{I}(d) + \text{MA}(q)$$

$$\text{AR}(p): y_t = c + \phi_1 \cdot y_{\{t-1\}} + \phi_2 \cdot y_{\{t-2\}} + \dots + \phi_p \cdot y_{\{t-p\}} + \varepsilon_t$$

(자기 자신의 과거 p 개 시점으로 회귀)

$$\text{I}(d): \text{원시 시계열을 } d \text{번 차분해 정상화}$$

(금리 레벨처럼 비정상이면 $d=1$ 차분으로 변화량으로 변환)

MA(q): $y_t = c + \varepsilon_t + \theta_1 \cdot \varepsilon_{t-1} + \dots + \theta_q \cdot \varepsilon_{t-q}$
(과거 q개 시점의 예측 오차를 가중 평균)

왜 이렇게 작동하는가

- **AR**: "오늘은 어제의 결과" — 시계열의 관성 모델링.
- **I**: 비정상성을 차분으로 제거 → 평균·분산이 시간에 일정해지면 회귀 가능.
- **MA**: 과거 충격(예: 갑작스런 외부 사건)이 며칠간 잔향처럼 남는 효과 모델링.
- 차수 (p, d, q) 결정: ACF(자기상관)·PACF(부분 자기상관) 그래프 시각 검사 + AIC/BIC 최소화.

강점

- **통계적 해석력**: 계수가 명확한 의미를 가짐 (φ_1 = 어제의 영향력 등).
- **소량 데이터로도 안정적 학습** (수백 시점이면 충분).
- 시계열 분야의 60년 표준 — 인용·검증 풍부.
- 차분으로 비정상성 처리하는 사고 방식 자체가 이후 모든 ML에 연결.

단점

- **단변량(univariate)**: 다른 거시 변수를 입력으로 못 받음. (확장형 ARIMAX/VARMA가 있지만 우리는 표준 ARIMA만).
- **선형 모델**: 비선형 관계·임계 효과·체제 전환 학습 불가.
- 구조 변화(regime shift)에 약함 — 예: 코로나·금융위기 시 계수가 의미 없어짐.

우리 프로젝트에서의 역할

- **시계열 자기상관 베이스라인**. XGBoost·LSTM이 단변량 시계열 구조 자체를 의미 있게 이기는지 검증.
- 만약 ARIMA가 LSTM과 비슷한 RMSE를 내면 → "다변량 거시 모델이 정말 필요한가" 의심 → 변수 선정·모델 구조 재검토 신호.

자주 받는 질문

- **Q. $d=1$ 로 차분하면 우리 타겟(Δy)과 같은 거 아닌가?** → 정확합니다. 우리가 Δy 로 직접 모델링하는 것과 ARIMA(p, 1, q)로 y 에 차분을 적용하는 것은 동치. 코드 단순화를 위해 Δy 를 직접 타겟으로 설정.

9.3 XGBoost (Extreme Gradient Boosting)

정의

약한 학습기(작은 결정 트리)를 **순차적으로 결합**하는 부스팅 알고리즘. 매 단계 이전 모델의 잔차(residual)를 예측하는 새 트리를 추가.

$F_0(x)$ = 초기 예측 (보통 평균)
 $F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x)$
 h_m 은 현재 잔차 $r_m = -\partial L / \partial F_{m-1}$ 에 fit

η = learning rate (0.01~0.3)

손실 함수 (분위수 회귀):

$L(y, \hat{y}) = \text{Pinball Loss} = \max(q \cdot (y - \hat{y}), (q - 1) \cdot (y - \hat{y}))$

XGBoost 추가 요소:

- 2차 테일러 근사 (Newton-style) → GBM보다 빠른 수렴
- L1/L2 정규화 → 과적합 방지
- 트리 분할 시 hessian 가중치

왜 이렇게 작동하는가

- **트리 = 자동 변수 선택 + 비선형/상호작용 학습기**. 분기 조건이 "us10y > 3.5%이면 ..."처럼 임계값을 자동 발견.
- **부스팅 = 약점 보완**. 첫 트리가 못 잡은 부분(잔차)을 다음 트리가 잡고, 이를 수십~수백 번 반복 → 약한 학습기 모음이 강해짐.
- **Pinball Loss를 손실 함수로 바꾸면 분위수 회귀 가능** — XGBoost는 `objective="reg:quantileerror"` 옵션 지원.

강점

- **표 데이터(tabular) 표준** — Kaggle 최다 우승 알고리즘.
- **변수 중요도 자동** + SHAP TreeExplainer가 빠르고 정확.
- **lag feature engineering 친화** — 시간 의존성을 lag 변수로 풀어주면 비선형 결합도 잘 잡음.
- 과적합 방지 도구 풍부 (정규화·early stopping·subsample).
- 학습 시간 합리적 (수천 시점·수십 변수면 분 단위).

단점

- **시계열 순서를 모름** — 입력 행을 섞어도 결과 동일. lag/rolling feature로 시간 의존성을 인공적으로 주입 필요.
- **외삽(extrapolation) 약함** — 학습 시 본 적 없는 범위(예: 금리 7%)를 예측 못함. 트리는 항상 학습 범위 내에서만 답.
- 분위수 동시 예측 시 분위수마다 별도 모델 필요 ($q=0.05/0.5/0.95$ → 모델 3개 학습).

우리 프로젝트에서의 역할

- **ML 표준 베이스라인 + 1주차 SHAP Hello World** 도구.
- LSTM이 의미 있는 우위를 보이려면 XGBoost를 이겨야 함. **만약 XGBoost가 LSTM과 비슷하거나 더 잘 나오면**: lag feature 기반의 단순 ML이 충분하다는 결론 → 모델 복잡도를 낮춰도 된다는 정직한 보고가 가능 (이것도 가치 있는 결과).

자주 받는 질문

- **Q. 왜 XGBoost가 LSTM보다 빠르면서도 메인이 아닌가?** → 일별 채권 데이터에서 lag로 인공 시간 의존성을 주입하면 한계가 있음. LSTM은 게이트 구조로 "**언제·무엇을 기억할지**"를 학습 → 위기/평상시 다른 패턴 학습 가능. 또 분위수 3개 동시 예측에 LSTM이 더 자연스러움 (단일 네트워크 출력층 3개).

- **Q. RandomForest 안 쓰는 이유?** → RF는 병렬 트리 평균 (배깅). 부스팅이 잔차를 순차 보완하므로 일반적으로 더 강하고, 분위수 회귀 지원이 XGBoost 쪽이 성숙.

9.4 LSTM 분위수 회귀 (Long Short-Term Memory + Pinball Loss)

정의 — 게이트 3개 + 셀 상태

LSTM은 RNN의 한 종류로 **셀 상태(c_t)**와 **은닉 상태(h_t)** 두 개를 매 시점 갱신.

```

입력 시점 t의 입력: x_t (그날 거시 변수 벡터, ~8 차원)
이전 상태: h_{t-1}, c_{t-1}

# Forget Gate - "어제까지의 셀 상태 중 무엇을 잊을 것인가"
f_t = σ(W_f · [h_{t-1}, x_t] + b_f)      # 0~1 사이 비율

# Input Gate - "새 정보 중 무엇을 받아들일 것인가"
i_t = σ(W_i · [h_{t-1}, x_t] + b_i)      # 0~1 사이 비율
g_t = tanh(W_g · [h_{t-1}, x_t] + b_g)   # 후보 새 정보 (-1~1)

# Cell State 갱신
c_t = f_t * c_{t-1} + i_t * g_t          # 잊을 거 잊고, 새로 받을 거 받기

# Output Gate - "셀 상태 중 무엇을 다음으로 출력할 것인가"
o_t = σ(W_o · [h_{t-1}, x_t] + b_o)
h_t = o_t * tanh(c_t)

# 마지막 시점 h_T를 받아 출력층 (3 분위수)
[q_0.05, q_0.5, q_0.95] = Linear(h_T)

# 손실: 분위수별 Pinball Loss 합
L = Σ_q max(q·(y-ŷ_q), (q-1)·(y-ŷ_q))

```

왜 이렇게 작동하는가

- **vanilla RNN의 vanishing gradient 문제:** 시점이 멀어질수록 그래디언트가 곱연산으로 0에 수렴 → 장기 의존성 학습 불가.
- LSTM은 **게이트로 셀 상태를 곱셈이 아닌 덧셈으로 갱신** → 그래디언트가 시간 축을 따라 죽지 않고 흐름 → 30~100 시점 의존성 학습 가능.
- **Forget Gate의 의미:** 위기 구간에서는 평상시 패턴을 빠르게 잊고 위기 패턴으로 전환 가능 → regime shift에 일정 부분 대응.
- **Pinball Loss:** q=0.05면 과대 예측에 큰 페널티, q=0.95면 과소 예측에 큰 페널티 → 비대칭 학습으로 분위수 직접 예측.

강점

- **장기 시계열 의존성 학습** — look-back 30일 + 게이트 구조로 어제·일주일 전·한 달 전 정보를 다르게 가중.
- **다변량 입력 자연스러움** — 입력 텐서 (시점, 변수) 형태로 22~27개 거시 변수 동시 학습.

- **분위수 동시 예측** — 단일 네트워크 출력층 3개로 $q=0.05/0.5/0.95$ 한 번에 산출. XGBoost처럼 분위수마다 모델 따로 학습 안 해도 됨.
- 비선형·상호작용 학습.

단점

- **데이터 굵주림** — 최소 수천 시점 권장. 우리 16년 $\approx 4,000$ 영업일은 LSTM에 적정 (Transformer에는 부족).
- **해석 어려움** — 왜 이렇게 예측했는지 직관 어려움. SHAP DeepExplainer로 보완하지만 트리 SHAP보다 부정확.
- **학습 시간** — XGBoost 대비 10~50배 느림 (CPU 기준 수십 분~수 시간).
- **분위수 교차(crossing)** — $q_{0.05} > q_{0.5}$ 같은 비논리적 출력 가능. 후처리 sort 또는 quantile crossing penalty로 해결.
- **하이퍼파라미터 민감** — hidden size-look-back-dropout-learning rate 모두 중요. 수동 grid 5×5로 탐색.

우리 프로젝트에서의 역할

- **메인 모델**. Naive-ARIMA-XGBoost 모두를 누른 뒤 SHAP 분위수별 분석으로 거시 인사이트 도출이 최종 목표.

자주 받는 질문

- **Q. 왜 Transformer가 아닌가?** → 데이터 규모. Transformer는 attention 파라미터가 많아 4,000일 데이터에서 과적합. 학술 문헌상 시계열 Transformer는 10만+ 시점에서 LSTM 우위. 우리 규모에서는 LSTM이 안정적·해석 가능.
- **Q. GRU와 LSTM 차이?** → GRU는 게이트 2개(reset, update)로 LSTM 단순화. 학습 빠르지만 장기 의존성은 LSTM이 약간 우세. 시간 여유 시 ablation 가능.
- **Q. 양방향 LSTM(BiLSTM)은?** → 금지. 미래 시점 정보를 사용 → 데이터 누수. 우리는 단방향만.
- **Q. Attention 메커니즘 추가 검토?** → §11 선택 확장 항목. LSTM + Attention으로 "어느 시점이 중요했는지" 시각화 가능. 7주 본문에서는 단순 LSTM 우선.

9.5 SHAP (SHapley Additive exPlanations) — 분석 도구

정의

협력 게임이론의 **Shapley value**를 ML 변수 기여도 분해에 적용. 한 예측에 대해 "각 변수가 평균 예측 대비 +/- 얼마 기여했는가"를 분배.

변수 i 의 SHAP 값 (예측 1건에 대해):

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! \cdot (|N| - |S| - 1)!}{|N|!} \cdot [v(S \cup \{i\}) - v(S)]$$

여기서:

N = 전체 변수 집합

S = N 에서 변수 i 를 뺀 모든 부분집합

$v(S)$ = 변수 S 만 사용했을 때의 모델 예측

직관: "변수 i 를 다른 변수들과의 모든 가능한 조합에 추가했을 때 모델 예측이 평균적으로 얼마나 변하는가"

왜 이렇게 작동하는가

- **공리적 보장 4가지** (수학적으로 유일한 분배 방식):
 1. **Efficiency**: 모든 변수 기여도 합 = (예측값 - 평균값).
 2. **Symmetry**: 동일 기여 변수는 동일 SHAP 값.
 3. **Dummy**: 영향력 없는 변수는 SHAP = 0.
 4. **Additivity**: 모델 합치면 SHAP도 합쳐짐.
- 이 4공리를 만족하는 분배는 Shapley value가 **유일**. 그래서 "정답"이라 부를 수 있는 변수 기여도.

구현체

- **TreeExplainer** (XGBoost·RF·LightGBM): 트리 구조 활용 다항 시간 정확 계산. 빠르고 정확.
- **DeepExplainer** (LSTM·신경망): DeepLIFT 근사. 트리보다 느리고 부정확하지만 가능.
- **KernelExplainer** (모델 무관): 매우 느림. 최후 수단.

강점

- **모델 무관**: XGBoost·LSTM 모두 적용 가능.
- **공리적 유일성**: "왜 이 분해가 정답인지" 수학적으로 보장.
- **시각화 우수**: summary plot, dependence plot, force plot 등 표준화.
- 변수 중요도(global) + 개별 예측 기여도(local) 모두 산출.

단점

- **DeepExplainer는 근사** — TreeExplainer만큼 정확하지 않음. 우리는 그래서 1주차에 XGBoost로 SHAP 흐름 먼저 검증 (Hello World) 후 4주차에 LSTM 적용.
- **변수 상관관계**가 강하면 기여도가 상관 변수들 사이에서 분산됨 → 해석 주의.
- **변수 간 상호작용**은 별도 SHAP interaction value로 봐야 함 (계산 비용 큼).
- 학부생에게 게임이론 배경 직관 어려움 → 발표에서 "공리 4개를 만족하는 유일한 변수 기여도 분해 방법" 정도로 압축.

우리 프로젝트에서의 역할

- **분위수별로 따로 SHAP 적용** ($q_{0.05}$ · $q_{0.5}$ · $q_{0.95}$ 각각의 모델 출력에 대해) 후 **차분 시각화**:
 - $q_{0.95}$ SHAP - $q_{0.05}$ SHAP = "이 변수가 예측 구간을 얼마나 넓혔는가"
- 위기 vs 정상 구간의 |SHAP| 평균 비교 → \$6.4(d) 4축 오류 분석의 한 축.
- **백업**: LSTM-SHAP이 안정성 문제로 실패하면 **Permutation Importance**로 대체 (정확도는 떨어지지만 모델 무관 동작 보장).

자주 받는 질문

- **Q. SHAP 대신 LIME 안 쓰는 이유?** → LIME은 국소 선형 근사로 빠르지만 일관성·공리적 보장 없음. SHAP이 학술·실무 표준.
- **Q. Permutation Importance와의 차이?** → PI는 변수 셔플 후 성능 하락 측정 (global only). SHAP은 개별 예측 단위 분해 가능 + 공리적 분배. 우리는 SHAP 메인, PI 백업.

9.6 모델 비교 한 눈 표

모델	다변량	비선형	시간 의존	분위수 출력	SHAP	학습 시간	데이터 요구	우리 역할
Naive	X	X	X	X	N/A	0	거의 0	최소 기준선
ARIMA	X (단변량)	X (선형)	✓ (명시)	X	N/A	초~분	수백 시점	시계열 베이스라인
XGBoost	✓	✓	△ (lag로)	✓ (모델 N개)	✓ Tree (정확)	분	수천 시점	ML 베이스라인 + SHAP Hello World
LSTM 분위수	✓	✓	✓ (게이트)	✓ (단일)	△ Deep (근사)	시간	수천+ 시점	메인 모델

9.7 모델 비교에서 자주 받는 종합 질문

Q. 왜 4개나 비교하나? 시간 낭비 아닌가?

A. 학술 문헌의 표준 — 각 모델이 잡는 패턴이 다름:

- Naive: random walk 가설.
- ARIMA: 단변량 시계열 자기상관.
- XGBoost: 다변량 lag 기반 비선형.
- LSTM: 다변량 + 시간 의존성 + 분위수 동시.

각 단계마다 "왜 이 복잡도가 필요한가"를 정량 입증. 단순 모델이 충분하다면 LSTM을 안 쓰는 게 정직한 결과 — 우리는 그것도 받아들임.

Q. 앙상블(여러 모델 평균)은 왜 안 하나?

A. 시간 제약 + 해석 복잡도. 7주 본문에서는 단일 LSTM 분위수 회귀로 메인 결과 도출. 앙상블은 §11 선택 확장 (XGBoost + LSTM 가중 평균으로 분위수 보강 등).

Q. Prophet(Facebook 시계열 모델)은?

A. Prophet은 추세·계절성·휴일 효과 자동 분해에 강하지만 일별 채권 변화량은 강한 계절성 없음 (월별 효과 약함). 또 분위수 회귀가 표준 출력이 아님. 우리 도메인에 적합도 낮음.

Q. N-BEATS·DeepAR 같은 최신 시계열 딥러닝은?

A. 데이터 규모 부족 (M3·M4 같은 대규모 시계열 경진대회용). 우리 4,000일에서는 과적합 위험. §11 선택 확장 검토.

Q. 강화학습으로 트레이딩 직접 학습하면?

A. 별도 프로젝트. 7주에 ML 핵심 역량(전처리·모델·평가·XAI) 모두 다루기로 한 안내문 §6과 어긋남. 후속 연구 항목.

9.8 발표 직전 30초 요약 (모델 한 줄씩)

- **Naive**: "내일도 오늘과 같다" — 모든 모델이 이겨야 할 최소 기준.
- **ARIMA**: 시계열 자기상관(과거 시점 회귀) + 차분으로 정상화. 단변량.
- **XGBoost**: 약한 트리 부스팅 + lag feature로 다변량 비선형 학습.
- **LSTM 분위수 회귀**: 게이트 3개로 장기 의존성 학습 + Pinball Loss로 90% 예측 구간 직접 출력. 메인.
- **SHAP**: 게임이론 Shapley value로 변수 기여도 분해 — "어느 변수가 예측 구간을 넓혔는가" 정량 분석.